

# Aprendizado profundo para detecção de espectro

Jiabao Gao, Xuemei Yi, Caijun Zhong, Xiaoming Chen e Zhaoyang Zhang

## Resumo - Nos sistemas de rádio cognitivo, a capacidade de precisão

detectar o sinal do usuário primário é essencial para o usuário secundário, a fim de utilizar o espectro licenciado ocioso. O detector de energia convencional é uma boa opção para detecção de sinal cego, enquanto sofre com a conhecida parede SNR devido à incerteza de ruído. Nesta carta, propomos em primeiro lugar um detector de sinal baseado em aprendizado profundo que explora as informações estruturais subjacentes dos sinais modulados, e é mostrado para alcançar o desempenho da detecção de última geração, sem a necessidade de conhecimento prévio sobre informações sobre o estado do canal ou ruído de fundo. Além disso, os impactos do esquema de modulação e o comprimento da amostra no desempenho são investigados. Finalmente, é proposto um sistema de detecção cooperativa baseado em aprendizado profundo, que é mostrado para fornecer ganho substancial de desempenho em relação aos métodos convencionais de detecção cooperativa.

**Termos do Índice** - detecção de espectro, parede SNR, aprendizado profundo, detecção cooperativa

## I. INTRODUÇÃO

O rádio cognitivo, que permite que dispositivos não licenciados utilizem oportunamente o espectro licenciado, como bandas de transmissão de TV, foi proposto como um método potencial para resolver o problema de escassez de espectro [1–3]. Um dos principais desafios para a implantação prática de sistemas de rádio cognitivo é fornecer proteção suficiente aos usuários licenciados. Portanto, a detecção confiável da presença de sinais primários, que geralmente são muito fracos, é de suma importância [4].

O detector de energia é um detector convencional amplamente utilizado devido à sua simplicidade. No entanto, o desempenho do detector de energia depende muito do conhecimento da densidade do ruído. Na prática, devido à existência de incerteza de ruído, o detector de energia falha quando a relação sinal / ruído (SNR) cai abaixo de algum limite, conhecido como parede SNR. De acordo com a literatura existente, a parede SNR para incerteza prática de ruído **é de cerca de - 6 dB, que está longe do limite de SNR de - 15 dB conforme exigido pelo IEEE 802.22.** Em [4], os autores sugeriram três abordagens diferentes para contornar o SNRwall, a saber, explorar a estrutura do sinal primário, usar a diversidade e reduzir a incerteza de ruído.

Como os usuários secundários geralmente não têm conhecimento prévio dos sinais primários, é desejável criar um método de detecção cega, que possa identificar a estrutura subjacente dos sinais primários. Recentemente, o aprendizado profundo (DL) demonstrou seu notável potencial em extrair a estrutura oculta de diferentes objetos em várias tarefas complicadas, como visão computacional [5] e comunicação sem fio [6]. Revisões abrangentes da aplicação de DL na camada física podem ser encontradas em [7] e [8]. No contexto da detecção de espectro, abordagens de aprendizado de máquina também foram propostas na literatura [9, 10]. Em particular, [10] propuseram uma

Método de detecção de espectro baseado em DL para sistemas OFDM, onde um autoencoder empilhado é usado para extração de recursos.

Motivados pelos resultados encorajadores de [10], nesta carta, propomos primeiro um detector baseado em DL usando redes neurais profundas convolucionais de longo prazo (CLDNN) [11], que é aplicável a tipos arbitrários de sinais primários. Vale ressaltar que o detector proposto não requer nenhuma informação adicional do sinal primário ou da densidade de ruído quando implantado on-line. Além disso, para melhorar ainda mais o desempenho da detecção, é proposta uma estratégia de combinação suave baseada em DL para detecção cooperativa. De acordo com os resultados da simulação, os métodos de detecção baseados em DL propostos superam significativamente os métodos convencionais.

## II P FORMULAÇÃO DE ROBLEMAS

Dependendo do estado ocioso ou ocupado do usuário primário, a detecção de sinal no usuário secundário pode ser modelada como o seguinte problema de teste de hipótese binária [12, 13]

$$\begin{aligned} \{W(n)\} &: H_{00} \\ y(n) &= hs(n) + W(n): H_{11} \end{aligned} \quad (1)$$

Onde  $y(n)$  é o  $n$ -th amostra recebida,  $s(n)$  é o sinal do usuário principal,  $h$  é o ganho de canal que se supõe permanecer inalterado durante o período de detecção [14], e  $W(n)$  é ruído aditivo após a distribuição Gaussiana complexa circularmente simétrica média zero (CSCG) com variação  $2\sigma_w^2$

Além disso,  $H_{00}$  e  $H_{11}$  são as duas hipóteses que denotam a ausência e presença de sinal primário em uma determinada banda, respectivamente.

Para o detector de energia convencional, a estatística de teste é a energia do sinal recebido normalizada em relação ao número da amostra  $N$  e variação de ruído  $2\sigma_w^2$  como indicado por [15]

$$\Lambda = 1 \frac{\sum_{n=1}^N |y(n)|^2}{2\sigma_w^2 N} \quad (2)$$

Portanto, as duas principais medidas de desempenho para o detector de energia, a probabilidade de falso alarme e a probabilidade de detecção perdida, podem ser expressas respectivamente como  $P_f = \Pr(\Lambda > \lambda | H_0)$  e  $P_{md} = \Pr(\Lambda < \lambda | H_1)$  Onde  $\lambda$  indica o limite de SNR. Além disso, a probabilidade de detecção é dada por  $P_d = 1 - P_{md}$ . Um bom detector precisa atingir níveis baixos  $P_f$  e  $P_{md}$  (Menor que 10%), mesmo em SNRs muito baixos.

Na prática, a densidade do ruído pode ser estimada usando apenas amostras de ruído, e a parede SNR sob determinado requisito de desempenho é fornecida por [15]

$$\gamma_{\min} = 1 - \frac{Q^{-1}(P_f) \sqrt{\phi}}{1 - Q^{-1}(P_f) \sqrt{\phi} - 1} \quad (3)$$

Onde  $N$  é o número da amostra para detecção,  $M$  é o número de amostras apenas de ruído,  $\phi$  é  $N+M$

$NM$ , e  $Q^{-1}(x)$  é o inverso

da função  $Q$  gaussiana.

### III DETECTOR BASEADO EM DL

Agora, apresentamos a estrutura de detecção baseada em DL. Em geral, o algoritmo de detecção  $D_{dl}$  pode ser expresso como

$$D_{dl}(y) = \text{argmax} (f_{Eu} f_{Eu-1} (f_{Eu-2} (\dots f_1(y))))), \quad (4)$$

onde a entrada  $y$  é o vetor de amostras recebidas, que é processado através de uma rede neural customizada que consiste em

eu camadas.  $f_{Eu}, i = 1 \dots, eu - 1$  representa para o cálculo com pesos e função de ativação do  $Eu$ -ª camada.  $f_{Eu}$  é a função SOFTMAX que fornece as probabilidades de duas hipóteses e  $\text{argmax}$  é um operador retornando o índice do maior número em uma lista.

#### A. Projeto de arquitetura de rede

Inspirados no resultado de [16], onde o CLDNN tem o melhor desempenho em tarefas de reconhecimento de modulação, também adotamos esse tipo de arquitetura nesta carta. A superioridade do CLDNN sobre outras arquiteturas de redes neurais populares também será validada através de simulações numéricas.

Acontece que uma rede com duas camadas de convolução (Conv), duas camadas de memória de longo prazo (LSTM), uma camada totalmente conectada (FC) após as camadas Conv e duas camadas FC após as camadas LSTM produzem o melhor desempenho. Para a função de ativação, o FC3 usa SOFTMAX, enquanto todas as outras camadas usam ReLu. O abandono também é usado após cada camada para evitar o excesso de ajustes. O modelo acima é denominado "DetectNet" e sua arquitetura de rede é ilustrada na Fig. 1. Os hiperparâmetros determinados por meio de ampla validação cruzada são detalhados na Tabela I.

Hiperparâmetro	Valor
Filtros por camada Conv	60
Tamanho do filtro	10
Células por camada LSTM	128
Neurônios por camada FC	128 & Comprimento da amostra & 2
Optimizer	Adão
Taxa inicial de aprendizado	0,0003
Tamanho do batch	200
Taxa de abandono	0,2

TABELA I. Hiperparâmetros do CLDNN proposto




Figura 1. Arquitetura de rede da DetectNet.

#### B. Geração e pré-processamento de conjuntos de dados

Para o conjunto de dados, geramos 8 tipos de sinais modulados digitalmente em diferentes SNRs como amostras positivas, conforme RadioML2016.10a [17], que é um conjunto de dados de linha de base amplamente usado em tarefas de reconhecimento de modulação, e as amostras negativas são ruídos de CSCG. Todo o conjunto de dados é dividido em três conjuntos diferentes para treinamento, validação e teste com um

Esquema de modulação	BPSK, QPSK, 8PSK, CPFSK QAM16, QAM64, GFSK, PAM4
Amostras por símbolo	8
Comprimento da amostra	64, 128, 256, 512, 1024
Gama SNR	- 20 ~ 20dB em incrementos de 1 dB
Amostras de treinamento	48000
Amostras de validação	16000
Amostras de teste	16000

TABELA II Parâmetros do conjunto de dados

usou a proporção de divisão de 3: 1: 1. Os parâmetros do conjunto de dados são detalhados na Tabela II.

Em vez de usar diretamente o sinal complexo recebido no domínio do tempo, a normalização de energia é realizada antes do treinamento ou da dedução. A motivação é tripla: 1) o impacto da energia acaba sendo mínimo, de acordo com os resultados da simulação,

2) a estrutura de modulação dos sinais pode ser melhor exposta sem a interferência da energia do sinal; 3) um modelo independente de energia pode ter uma melhor capacidade de generalização que pode funcionar bem, mesmo que o ruído de fundo seja alterado.

#### C. Treinamento personalizado em duas etapas

Duas principais medidas de desempenho para detecção de sinal, a saber:

**$P_r$  e  $P_d$  não pode ser obtido diretamente da biblioteca DL. Portanto, uma função de retorno de chamada no Keras é implementada para computá-los para diferentes SNRs no final de cada época.**

Considerando o detector de taxa de alarme falso constante (CFAR), uma estratégia de treinamento em dois estágios é projetada. No primeiro estágio, uma parada precoce com 6 épocas de paciência é aplicada para treinar o modelo para a convergência. No segundo estágio, a característica de troca de métricas é observada que a perda e a precisão da validação mantêm-se estáveis enquanto  $P_r$  e  $P_d$  em diferentes SNRs varia de época para época. Portanto, estabelecemos um  $P_r$  para o intervalo primeiro, continue com o melhor modelo no primeiro estágio e pare o treinamento quando  $P_d$  cai nele. Uma desvantagem dos métodos de DL é a falta de controle preciso do desempenho, aplicando a estratégia de treinamento em dois estágios, podemos controlar o desempenho da detecção em certa medida, ajustando o intervalo de parada predefinido. A troca entre precisão de controle e tempo de treinamento é alcançada pelo parâmetro de tamanho do intervalo. Um intervalo menor atinge um controle de desempenho mais preciso, mas também resulta em maior tempo de treinamento.

#### D. Resultados da Simulação

Nesta seção, são fornecidos extensos resultados de simulação para demonstrar o desempenho do modelo proposto. <sup>11</sup> Além disso, o impacto de parâmetros-chave, como esquema de modulação e comprimento da amostra, é investigado.

**1) Comparação com redes diferentes:** A Fig. 2 compara o desempenho de detecção do modelo proposto com vários outros modelos populares de redes neurais nos sinais QAM16 com comprimento de amostra de 128. Para uma comparação justa, é realizada extensa validação cruzada para todos os modelos para determinar os melhores hiperparâmetros. Em particular, todos os modelos usam abandono de 0,2. O DNN consiste em quatro camadas de FC com 256, 500, 250, 120 neurônios, respectivamente, a CNN usa duas camadas de Conv com 60

<sup>11</sup> Para pesquisa reproduzível, todos códigos fonte podem ser encontrados em <https://github.com/EricGJB/DL-based-signal-detection>.




Figura 2. Desempenho de detecção para vários modelos de DL.

filtros com tamanho de filtro de 10 e uma camada FC com 128 neurônios, enquanto o LSTM usa duas camadas LSTM de 128 células.

Pode-se observar que DetectNet e CNN alcançam melhor desempenho de detecção que DNN e LSTM. Além disso, a DetectNet obtém  $P_d$  CNN, mas supera a CNN alcançando níveis mais baixos  $P_f$ . Para ilustrar a vantagem do DetectNet sobre o detector de energia, considerando o ponto de operação com

$P_f = 5,92\%$  e  $P_d = 90\%$  De acordo com a Equação 3, a parede SNR do detector de energia é de -5,35 dB. Na Fig. 2, a parede SNR do DetectNet é de -8,5 dB, ou seja, 3,15 dB mais baixo.




Fig. 3. Impacto do esquema de modulação no desempenho.

**2) Impacto do esquema de modulação:** A Fig. 3 ilustra o desempenho de detecção do DetectNet em diferentes tipos de esquemas de modulação com comprimento de amostra de 128. Como pode ser observado, o desempenho para os sinais FSK, especialmente GFSK, é melhor do que para os sinais PSK e QAM. Além disso, é surpresa ver que a diferença de desempenho de detecção entre BPSK, QPSK e 8PSK é bastante insignificante, o que implica que o desempenho do DetectNet é insensível à ordem de modulação.

**3) Capacidade de generalização:** A Fig. 4 ilustra a capacidade de generalização da DetectNet proposta. Em particular, testamos o desempenho de detecção de uma rede bem treinada em sinais com esquemas de modulação diferentes dos sinais de treinamento. Comparando a Fig. 3 e a Fig. 4, pode-se observar facilmente que, desde que o tipo de modulação seja o mesmo, por exemplo, QAM16 e QAM64 ou BPSK e QPSK, o DetectNet fornece uma capacidade de generalização decente. Por outro lado, se o tipo de modulação for diferente, por exemplo, BPSK e GFSK, haverá uma deterioração significativa do desempenho. A razão é bastante

intuitivo, já que o DetectNet explora informações estruturais subjacentes de sinais modulados, o que é semelhante entre sinais com o mesmo tipo de modulação, enquanto difere substancialmente entre sinais com diferentes tipos de modulação.

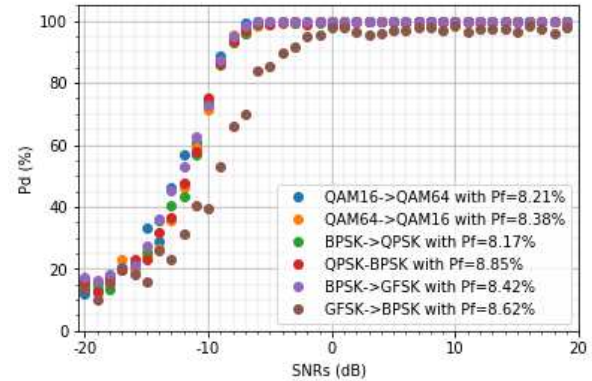


Fig. 4. Capacidade de generalização para diferentes modulações esquemas.

**4) Impacto do comprimento da amostra:** Intuitivamente, o desempenho de detecção do DetectNet melhora quando o comprimento da amostra aumenta devido a mais informações disponíveis. Lembre-se de que o desempenho da detecção do detector de energia também melhora com o comprimento da amostra mais longo; portanto, é de particular interesse observar a diferença de desempenho dos dois detectores com comprimentos de amostra diferentes. Vamos considerar os pontos operacionais com  $P_d = 90\%$

e defina o  $P_f$  intervalo de parada como [7%, 9%], então os SNRwalls do detector de energia e os sinais DetectNet nos GFSK com diferentes comprimentos de amostra estão resumidos na Tabela III. Acontece que, independentemente do comprimento da amostra, o DetectNet produz consistentemente melhorias em torno de 5dB em relação ao detector de energia.

$P_f$ (%)	Comprimento da amostra	EDW	DLW	Improvement
8.05	64	-3,91	-9,00	5.09
7.34	128	-5,57	-11,00	5,43
8,45	256	-7.41	-12,30	4,89
7,73	512	-8,94	-13,50	4.56
7.86	1024	-10,55	-15,60	5.05

TABELA III Melhoria da parede SNR para diferentes amostras comprimentos. EDW e DLW representam para parede SNR de detector de energia e detector baseado em DL, respectivamente. O EDW é calculado pela Eq. 3 com  $M \rightarrow \infty$ . A unidade da parede SNR é dB.

#### IV DETECÇÃO COOPERATIVA BASEADA EM DL

A detecção cooperativa, que utiliza nós distribuídos para trabalhar de maneira colaborativa, demonstrou ser um meio eficiente para melhorar o desempenho da detecção. Para detecção cooperativa, o centro de fusão toma a decisão final com base nas informações concretas de cada nó sensor. Como tal, não é capaz de explorar as informações de confiança da decisão de cada nó. Além disso, a prioridade de diferentes nós não é usada. Motivado por isso, nesta seção, apresentamos um sistema de detecção cooperativa baseado em DL que explora implicitamente essas informações flexíveis.

### A. Projeto do sistema

Para cada nó sensor, o DetectNet é empregado localmente para obter o vetor de probabilidade de duas hipóteses sobre o sinal primário. Em seguida, é alimentado no centro de fusão para processamento adicional. Diferente do sistema de detecção convencional, onde uma regra de fusão específica é usada para combinar as informações de decisão rígidas dos nós distribuídos, uma rede neural composta por três camadas de FC é proposta para aprender diretamente a melhor regra de fusão através do treinamento.

Através de ampla validação cruzada, o número de neurônios de cada camada de FC é dado por 32, 8 e 2, respectivamente. O modelo do sistema de detecção cooperativa é denominado "SoftCombinationNet" e a arquitetura de rede detalhada é ilustrada na Fig. 5.




Fig. 5. Projeto de sistema de detecção cooperativa baseado em DL.

### B. Resultados da simulação

Para simulações, assume-se que o canal ganha entre o transmissor primário e  $k$  nós sensores são distribuídos de forma independente e idêntica (iid). Além disso, são realizadas experiências em sinais QAM16 com um comprimento de amostra de 128 e três sistemas cooperativos com 2, 4 e 8 nós, respectivamente, são considerados.

A Fig. 6 mostra o desempenho de detecção de esquemas de detecção cooperativa. Para fins ilustrativos, a regra Logical-OR (LO) é usada no esquema convencional de detecção cooperativa, uma vez que geralmente produz a maior  $P_d$ . Comparando o desempenho do SoftCombinationNet (SCN) e LO, descobrimos que, para todos os três sistemas, no regime prático de interesses SNR, ou seja, onde  $P_d$  é superior a 90%, o SoftCombinationNet alcança quase o mesmo  $P_d$  como LO, mas com uma redução significativa no  $P_f$  demonstrando assim sua supremacia.

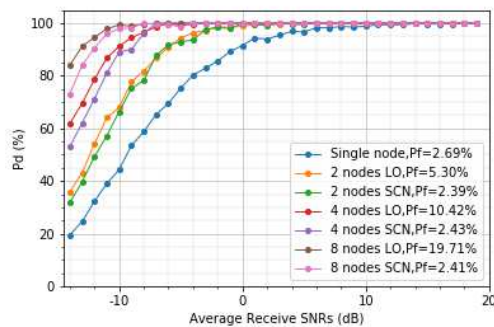


Fig. 6. Ganho de desempenho do sistema de detecção cooperativa baseado em DL.

## V. CONCLUSÃO

Nesta carta, propusemos um novo detector de sinal baseado em DL chamado DetectNet, que explora as informações estruturais inerentes aos sinais modulados. Foi demonstrado que uma melhoria significativa no desempenho pode ser alcançada em relação ao detector de energia convencional. Além disso, o detector baseado em DL é insensível à ordem de modulação, portanto, possui boa capacidade de generalização para esquemas de modulação semelhantes. Em seguida, propõe-se um esquema de detecção cooperativa baseado em DL, denominado SoftCombinationNet, para explorar as informações flexíveis dos nós de detecção distribuídos, o que é mostrado para alcançar alta  $P_d$  e baixo  $P_f$  simultaneamente.

## REFERÊNCIAS

- [1] S. Zhang, et al., "Novo espectro de detecção e acesso no rádio cognitivo redes" *Sci. China Inf. Sci.*, vol. 61, n. 8, 089302, agosto de 2018. [2] J. Zhao, X. Guan e X. Li, "Alocação de energia baseada em genética algoritmo de recozimento simulado em redes de rádio cognitivas" *Revista chinesa de eletrônica*, vol. 22, n. 1, pp. 177-180, janeiro de 2013. [3] J. Zhao, T. Yang, Y. Gong, J. Wang e L. Fu, "Power control algoritmo do rádio cognitivo baseado na teoria dos jogos não cooperativa" *China Commun.*, vol. 10, n. 11, pp. 143-154, novembro de 2013. [4] R. Tandra e A. Sahai, "Paredes SNR para detecção de sinal" *IEEE J. Sel. Tópicos Signal Process.*, vol. 2, no.1, pp. 4-17, fevereiro de 2018. [5] A. Krizhevsky, I. Sutskever e GE Hinton, "Classificação Imagenet com profundas redes neurais convolucionais" *Proc. Adv. Neural Inf. Process. Syst.*, 2012, pp. 1097-1105.
- [6] P. Jiang et al. "Artificial Receptor OFDM auxiliado por inteligência: Projeto e experimental resultados", 2018. [Conectados]. Acessível: <https://arxiv.org/abs/1812.06638> [7] X. Você, et al, "IA para 5G: direções e paradigmas de pesquisa" *Sci. China Inf. Sci.*, vol. 62, n. 2, 021301, fevereiro de 2019. [8] T. Wang, et al, "Aprendizado profundo da camada física sem fio: oportunidades e desafios" *China Commun.*, vol. 14, n. 11, pp. 92-111, novembro de 2017. [9] F. Azmat, Y. Chen e N. Stocks, "Análise da ocupação do espectro usando algoritmos de aprendizado de máquina" *IEEE Trans. Veh. Technol.*, vol. 65, n. 9, pp. 6853-6860, setembro de 2016. [10] Q. Chen et al. "Sensores de espectro baseados em redes de aprendizado profundo métodos para sistemas OFDM", 2019. [Conectados]. Acessível: <https://arxiv.org/pdf/1807.09414.pdf>
- [11] TN Sainath et al., "Convolutacional, memória de longo prazo, totalmente redes neurais profundas conectadas", em Proc. 2015 IEEE ICASSP, 2015, pp. 4580-4584.
- [12] Y. Liang, Y. Zeng, EY Peh e AT Hoang, "Sensing-throughput tradeoff para redes de rádio cognitivas", *IEEE Trans. Comunicação sem fio.*, vol. 7, n. 4, pp. 1326-1337, abril de 2018. [13] Z. Quan, S. Cui, AH Sayed e HV Poor, "Multibanda ideal detecção conjunta para detecção de espectro em redes de rádio cognitivas", *IEEE Trans. Processo de sinal.*, vol. 57, n. 3, pp. 1128-1140, março de 2009. [14] S. Atapattu, C. Tellambura e H. Jiang, "Detector de energia convencional" no *Detecção de energia para detecção de espectro em rádio cognitivo* (Springer Briefs em Ciência da Computação). Nova York, NY, EUA: Springer, 2014, pp. 11-26.
- [15] A. Mariani, A. Giorgetti e M. Chiani, "Efeitos da potência sonora estimativa de detecção de energia para aplicações de rádio cognitivas" *IEEE Trans. Comum.*, vol. 59, n. 12, pp. 3410-3420, dezembro de 2011. [16] NE West e TJ O'Shea, "Arquiteturas profundas para modulação reconhecimento", em Proc. 2017 IEEE DySPAN, 2017, pp. 1-6. [17] TJ O'Shea e N. West, "Geração de conjuntos de dados de aprendizado de máquina de rádio com rádio gnu", em *Anais da Conferência de Rádio GNU*, vol. 1, n. 1 de 2016.